Σχεδιασμός και Υλοποίηση Κλιμακώσιμου Συστήματος Διαχείρισης Χωροχρονικών Ναυτιλιακών Δεδομένων (AIS) στη MongoDB

Χρήστος Τσάμης
A.M. me25038
xristostsamis941998@gmail.com

Περίληψη

Στόχος της συγκεκριμένης εργασίας είναι ο σχεδιασμός και η υλοποίηση μιας μη σχεσιακής βάσης δεδομένων (MongoDB) που περιλαμβάνει χωροχρονικά ναυτιλιακά δεδομένα(AIS) εμπλουτισμένα με δεδομένα καιρού. Ο εμπλουτισμός έγινε μέσω μιας διαδικασίας ETL, τμηματοποιώντας τα δεδομένα και επιτυγχάνοντας ακριβή χωροχρονική συσχέτιση. Τέλος εφαρμόστηκε το πρότυπο σχεδίασης **Bucket Pattern** σε συνδυασμό με γεωχωρικά ευρετήρια.

1. Εισαγωγή

Τα δεδομένα AIS (Automatic Identification System) είναι τεράστια σε όγκο και παράγονται με ταχύτατους ρυθμούς. Η απλή αποθήκευση αυτών των δεδομένων δεν προσφέρει επαρκή πληροφορία για την κατανόηση της συμπεριφοράς των πλοίων. Εκ τούτου είναι αναγκαίος ο εμπλουτισμός τους με δεδομένα καιρού ώστε να παραχθούν ουσιαστικά συμπεράσματα (π.χ. πως ο άνεμος επηρεάζει την ταχύτητα των πλοίων).
Στόχος μας είναι ο σχεδιασμός και η υλοποίηση μιας μη σχεσιακής βάσης (MongoDB) η οποία θα διαχειρίζεται τον μεγάλο όγκο δεδομένων. Βασικό χαρακτηριστικό είναι η σύνδεση των χωροχρονικών δεδομένων των πλοίων AIS με δεδομένα καιρού, επιτυγχάνοντας ακριβή χωροχρονική συσχέτιση (Spatio-Temporal Join).

2. Σχετικές Εργασίες και Ανασκόπηση Βιβλιογραφίας

2.1 Προκλήσεις των μεγάλων δεδομένων στη ναυτιλία (Maritime Big Data)

Η υιοθέτηση του AIS (Automatic Identification System) από τον Διεθνή Ναυτιλιακό Οργανισμό (IMO) αύξησε απότομα τον όγκο των διαθέσιμων ναυτιλιακών δεδομένων. Κάθε μέρα εκατομμύρια στίγματα δίνουν θέση, ταχύτητα και ταυτότητα πλοίων. Η βιβλιογραφία σημειώνει ότι τα κλασικά Συστήματα Διαχείρισης Σχεσιακών Βάσεων Δεδομένων (RDBMS), όπως η MySQL και η

PostgreSQL, δυσκολεύονται στην απόδοση όταν πρέπει να χειριστούν τόσο μεγάλο όγκο δεδομένων, κυρίως στην ταχύτητα εγγραφής και στην εκτέλεση σύνθετων γεωχωρικών ερωτημάτων **[1]**.

2.2 Μετάβαση σε NoSQL και Χωροχρονικές Βάσεις

Για να αντιμετωπιστούν τα παραπάνω ζητήματα, η ερευνητική κοινότητα στράφηκε στις βάσεις δεδομένων NoSQL. Σύμφωνα με την βιβλιογραφική ανασκόπηση **[2]**, τα document-oriented συστήματα, όπως η MongoDB, έχουν σημαντικά πλεονεκτήματα χάρη στο ευέλικτο μοντέλο τους και τη δυνατότητα οριζόντιας κλιμάκωσης μέσω διαμοιρασμού (sharding).
Η χρήση γεωχωρικών ευρετηρίων, όπως το 2dsphere της MongoDB και τα R-trees, θεωρείται καλή πρακτική, γιατί επιταχύνει την ανάκτηση σημείων μέσα σε συγκεκριμένα γεωγραφικά πολύγωνα. Όπως αναφέρει ο Zheng στην επισκόπησή του για την επεξεργασία τροχιών **[3]**, η τμηματοποίηση και η ομαδοποίηση των σημείων είναι απαραίτητες τεχνικές για τη μείωση του υπολογιστικού κόστους. Στην παρούσα εργασία, υιοθετήθηκε το Bucket Pattern, ομαδοποιώντας πολλαπλά στίγματα σε ενιαία έγγραφα, με στόχο τη μείωση των λειτουργιών I/O και τη βελτιστοποίηση της ανάγνωσης.

2.3 Καιρικά δεδομένα στη δρομολόγηση (Weather Routing)

Ένα σημαντικό αντικείμενο έρευνας είναι η συσχέτιση δεδομένων κίνησης με περιβαλλοντικούς παράγοντες. Η πορεία ενός πλοίου επηρεάζεται άμεσα από τον άνεμο και τον κυματισμό. Η μελέτη αυτών των παραγόντων είναι βασική για τον σχεδιασμό διαδρομής (Weather Routing) και τη μείωση της κατανάλωσης καυσίμων. Πολλές μέθοδοι στηρίζονται σε στατικά μοντέλα ή κλειστό εμπορικό λογισμικό. Η σημερινή ακαδημαϊκή έρευνα στρέφεται στην ανάπτυξη ανοιχτών αλγορίθμων που εκτελούν χωροχρονική συσχέτιση (Spatio-temporal Join) ανάμεσα στις τροχιές πλοίων και στα μετεωρολογικά πλέγματα (GRIB files). Η δυσκολία είναι ότι τα δεδομένα καιρού και πλοίων έχουν διαφορετική χωρική και χρονική δειγματοληψία, οπότε

χρειάζονται αλγόριθμοι interpolation και nearest-neighbor search, όπως στη μελέτη **[4]**.

3. Περιγραφή Δεδομένων

Για την υλοποίηση της βάσης χρησιμοποιήθηκαν τρεις πηγές δεδομένων, οι οποίες ενώθηκαν κατά την διαδικασία ETL. Τα δεδομένα αυτά καλύπτουν τις τροχιές των πλοίων, τα στατικά χαρακτηριστικά τους και τις περιβαλλοντικές συνθήκες.

3.1 Δεδομένα Κίνησης Πλοίων (AIS Dynamic Data)

Τα βασικά δεδομένα που αποτελούνται από τα στίγματα των πλοίων σε μορφή CSV. Χρησιμοποιήθηκε μόνο το CSV του Αυγούστου 2017(unipi_ais_dynamic_aug2017.csv ~1 GB ~8 εκατομμύρια εγγραφές το οποίο μετονομάστηκε στο περιβάλλον εκτέλεσης σε ais_data.csv) για λόγους διευκόλυνσης, παρόλα αυτά οι διαδικασίες που θα αναλυθούν στην συνέχεια δουλεύουν και με περισσότερα αρχεία CSV χωρίς κάποιες τεράστιες αλλαγές στον κώδικα. Τα αρχεία AIS Dynamic Data περιέχουν τα εξής χαρακτηριστικά:

- **Timestamp (t):** Η χρονική στιγμή της καταγραφής (Unix epoch time), η οποία μετατράπηκε σε μορφή ημερομηνίας/ώρας.
- **Geospatial Coordinates (lon, lat):** Το γεωγραφικό μήκος και πλάτος του πλοίου.
- **Speed (speed):** Η ταχύτητα του πλοίου σε κόμβους (knots).
- **Heading/Course:** Η κατεύθυνση της πλώρης και η πορεία του πλοίου (σε μοίρες).
- **MMSI (vessel_id):** Ο μοναδικός αριθμός ταυτοποίησης του πλοίου, ο οποίος χρησιμοποιήθηκε ως κλειδί ομαδοποίησης (Sharding Key candidate).

3.2 Στατικά Δεδομένα Πλοίων (AIS Static Data)

Επειδή το αρχείο με τα δεδομένα κίνησης των πλοίων δεν περιέχει καθόλου την στατική πληροφορία τους, χρησιμοποιήθηκε το αρχείο unipi_ais_static.csv για τον εμπλουτισμό της πληροφορίας. Συγκεκριμένα αυτά τα αρχεία χρησιμοποιήθηκαν σαν πίνακας αντιστοίχισης του MMSI(vessel_id) με το **Country/Flag** (τη χώρα προέλευσης του πλοίου).

Όσον αφορά την αποκωδικοποίηση των τύπων πλοίων (Ship Type Codes), η πληροφορία του αρχείου ais_codes_descriptions.csv **ενσωματώθηκε απευθείας στη λογική της εφαρμογής (in-memory static mapping)**. Η τεχνική αυτή επιλογή (hardcoding) χρησιμοποιήθηκε για τη βελτιστοποίηση της απόδοσης, εξαλείφοντας περιττές λειτουργίες εισόδου/εξόδου (I/O overhead), δεδομένου ότι το πρότυπο κωδικοποίησης των πλοίων είναι σταθερό και αμετάβλητο.

Η πληροφορία αυτή είναι χρήσιμη για την ανάλυση, καθώς επιτρέπει την κατηγοριοποίηση της συμπεριφοράς ανάλογα με τον τύπο του σκάφους (π.χ. σύγκριση αντοχής σε μποφόρ μεταξύ Ρυμουλκών και Επιβατηγών).

3.3 Μετεωρολογικά Δεδομένα (NOAA Weather Data)

Τα δεδομένα καιρού πάρθηκαν από το National Oceanic and Atmospheric Administration (NOAA) με σκοπό τον εμπλουτισμό των τροχιών με χαρακτηριστικά περιβάλλοντος. Τα δεδομένα αυτά διατίθενται σε μορφή shapefile μέσα σε φακέλους ανά έτος και μήνα. Τα αρχεία περιέχουν την εξής πληροφορία που μας χρησιμεύει για την χωροχρονική σύνδεση με της τροχίες :

- timestamp : Η ημερομηνία και ώρα της μέτρησης (π.χ. 2017-07-01 00:00:00).
- timestamp_ : Η ίδια ώρα σε μορφή Unix Epoch (δευτερόλεπτα από το 1970).
- lon / lat : Γεωγραφικό Μήκος και Πλάτος του σημείου μέτρησης.
- geometry : Το γεωμετρικό αντικείμενο (POINT) που χρησιμοποιεί το Geopandas.

Αλλά και πληροφορία περιβάλλοντος. Ενδεικτικά κάποια χαρακτηριστικά περιβάλλοντος :

- TMP (Temperature) σε Kelvin
- PRMSL (Pressure Reduced to Mean Sea Level) σε Pascal
- RH (Relative Humidity)
- WSPD (Wind Speed)

Η ετερογένεια των παραπάνω πηγών (CSV και Shapefiles) καθιστά αναγκαία τη χρήση διαδικασίας ETL για την ομογενοποίηση και αποθήκευσή τους σε ενιαία δομή εγγράφου.

4 Αρχιτεκτονική Συστήματος & Υλοποίηση

Η βάση υλοποιήθηκε με τρεις βασικούς πυλώνες σχεδιασμού:
1. Φορητότητα
2. Αποδοτική διαχείριση του μεγάλου όγκου δεδομένων
3. Χωροχρονική συσχέτιση των δεδομένων
4. Βελτιστοποίηση σχήματος βάσης

4.1 Περιβάλλον Εκτέλεσης (Dockerized Environment)

Η ανάπτυξη του συστήματος πραγματοποιήθηκε σε απομονωμένο περιβάλλον Docker Container. Η επιλογή αυτή καθιστά την διαδικασία αναπαραγωγής της βάσης ανεξάρτητη από το λειτουργικό σύστημα του κάθε ενδιαφερόμενου. Διασφαλίζοντας τον ορισμό των απαραίτητων βιβλιοθηκών (pandas, geopandas, pymongo, rtree, scipy) αλλά και τις ρυθμίσεις δικτύου για την επικοινωνία με την βάση MongoDB.

4.2 Διαχείριση Μνήμης και Στρατηγική Τμηματοποίησης (Memory Management & Chunking Strategy)

Λόγο του μεγάλου όγκου δεδομένων που υπάρχουν σε αυτό το πρόβλημα η φόρτωση και επεξεργασία τεράστιων αρχείων στην RAM κρίνεται μη βιώσιμη. Επομένως χρησιμοποιήσαμε τεχνική τμηματοποιημένης επεξεργασίας (Chunking). Ο αλγόριθμος ETL διαβάζει τα δεδομένα εισόδου σε τμήματα (chunks) των 10.000 εγγραφών. Κάθε τμήμα επεξεργάζεται, εμπλουτίζεται αποθηκεύεται και στην συνέχεια απελευθερώνετε από την μνήμη. Αυτή η προσέγγιση επιτρέπει στο σύστημα να επεξεργαστεί αρχεία απεριόριστου μεγέθους (οριζόντια κλιμάκωση) δίχως να εμφανίζετε πρόβλημα μνήμης.

4.3 Αλγόριθμος Χωροχρονικής Συσχέτισης (Spatio-Temporal Join Algorithm)

Η κρίσιμη λειτουργία της υλοποίησης είναι η σύνδεση των τροχιών των πλοίων με τα δεδομένα καιρού. Καθώς η οντότητα των πλοίων αλλά και των μετεωρολογικών σταθμών αναπαρίσταται ως γεωμετρικά σημεία αναπτύχθηκε αλγόριθμος εύρεσης του πλησιέστερου γείτονα στον χώρο και στον χρόνο σε τρία στάδια :

1. **Χρονικό φιλτράρισμα:** Αρχικά φορτώνονται στην μνήμη μόνο τα δεδομένα καιρού που αφορούν το συγκεκριμένο τμήμα με βάση τον μήνα. Πριν την γεωμετρική σύγκριση απομονώνονται οι μετρήσεις καιρού που βρίσκονται σε χρονικό παράθυρο +/- 3 ωρών από τα στίγματα του τρέχοντος τμήματος (chunk). Αυτό μειώνει δραματικά τον όγκο των προς σύγκριση δεδομένων.
2. **Γεωχωρική Συσχέτιση:** Στο μειωμένο πλέον σύνολο, εφαρμόζεται η μέθοδος sjoin_nearest της βιβλιοθήκης geopandas. Για κάθε στίγμα πλοίου, εντοπίζεται ο πλησιέστερος μετεωρολογικός σταθμός σε μέγιστη ακτίνα αναζήτησης 0.15 μοιρών.
3. **Χρονική Ελαχιστοποίηση:** Τέλος, επειδή ένας μετεωρολογικός σταθμός περιέχει πολλές μετρήσεις υπολογίζεται η απόλυτη χρονική διαφορά (|timestamp_πλοίου – timestamp_μέτρησης_καιρού|) και επιλέγεται η εγγραφή με την μικρότερη απόκλιση. Με αυτόν τον τρόπο εξασφαλίζεται ότι η καιρική συνθήκη αντιστοιχεί ακριβώς στη στιγμή διέλευσης του πλοίου.

4.4 Σχεδιασμός Σχήματος Βάσης (Database Schema: The Bucket Pattern)

Για την αποθήκευση στην MongoDB επιλέχθηκε το πρότυπο bucket pattern έναντι του κλασσικού τρόπου όπου ένα έγγραφο αντιστοιχεί σε ένα στίγμα. Στην περίπτωση ενός εγγράφου ανά στίγμα θα είχαμε εκατομμύρια έγγραφα καθιστώντας έτσι υπερβολικά αργή την εύρεση τροχιών. Αντιθέτως εφαρμόζοντας bucket pattern κάθε έγγραφο στην βάση περιέχει ένα χρονικό παράθυρο 6 ωρών για ένα συγκεκριμένο πλοίο. Με αυτό τον τρόπο μειώνεται δραματικά το μέγεθος των ευρετηρίων αλλά και του χρόνο ανάγνωσης του δίσκου που απαιτητέ για ένα τμήμα του ταξιδιού. Συγκεκριμένα το κάθε έγγραφο περιέχει :

- ship_id: Το αναγνωριστικό του πλοίου (Sharding Key).
- bucket_period: Το χρονικό εύρος (Start/End).
- static_data: Τα σταθερά στοιχεία (Τύπος, Χώρα).
- points: Μια λίστα (Array) που περιέχει όλα τα στίγματα και τα αντίστοιχα δεδομένα καιρού για εκείνο το 6ωρο.

Ακολουθεί ένα δείγμα εγγράφου από τη βάση δεδομένων, όπου φαίνεται ο επιτυχής εμπλουτισμός με τα μετεωρολογικά δεδομένα (weather object):


```
[
  {
    _id: ObjectId('6980a199ba2cc5e3edee7203'),
    ship_id: 'c2fdc46613a781f229895e2a8591fba33194aede439531587506fcb2052f9d25',
    static_data: { country: 'Greece', vessel_type: 'Passenger' },
    bucket_period: {
      start: ISODate('2017-08-10T11:02:45.000Z'),
      end: ISODate('2017-08-10T11:37:35.000Z')
    },
    points: [
      {
        ts: ISODate('2017-08-10T11:02:45.000Z'),
        location: { type: 'Point', coordinates: [ 23.55615, 37.96371666666671 ] },
        speed: 0.1,
        heading: 0,
        course: 62.1,
        weather: {
          temp_c: 26.3,
          wind_speed: 5.8,
          wind_gust: 3.8,
          humidity: 72.36426,
          pressure: 101523.45,
          time_offset_min: 57.2
        }
      },
      {
        ts: ISODate('2017-08-10T11:02:54.000Z'),
        location: { type: 'Point', coordinates: [ 23.55615, 37.96371666666671 ] },
        speed: 0.1,
        heading: 0,
        course: 31.8,
        weather: {
          ts: ISODate('2017-08-10T16:19:54.000Z'),
          location: {
            type: 'Point',
            coordinates: [ 23.631333333333306, 37.9411666666667 ]
          },
          speed: 0,
          heading: 249,
          course: 302,
          weather: {
            temp_c: 26.3,
            wind_speed: 5.8,
            wind_gust: 3.8,
            humidity: 72.36426,
            pressure: 101523.45,
            time_offset_min: 79.9
          }
        }
      ],
      point_count: 378
    }
]
```


Στο σχήμα της βάσης δεδομένων έχει δημιουργηθεί το πεδίο point_count ως υπολογιζόμενο πεδίο. Η τιμή του λειτουργεί ως προϋπολογισμένος μετρητής του αριθμού των στιγμάτων που υπάρχουν στον πίνακα points, ώστε να είναι διαθέσιμο το πλήθος χωρίς να απαιτείται κάθε φορά νέος υπολογισμός. Η τεχνική αυτή

(Computed Pattern) επιλέχθηκε με στόχο τη βελτίωση της απόδοσης. Επιτρέπει την άμεση εκτέλεση ερωτημάτων φιλτραρίσματος (π.χ. απόρριψη εγγραφών με ελλιπή δεδομένα ή θόρυβο, όπου count < 5) χωρίς να απαιτείται η υπολογιστικά δαπανηρή λειτουργία $size επί του πίνακα κατά την εκτέλεση του ερωτήματος.

4.5 Στρατηγική Ευρετηρίασης (Indexing Strategy)

Τέλος για τον βέλτιστο χρόνο απόκρισης ερωτημάτων δημιουργήθηκαν τα κατάλληλα ευρετήρια καλύπτοντας τις ανάγκες τόσο της γεωχωρικής όσο και της περιγραφικής αναζήτησης. Συγκεκριμένα δημιουργήθηκαν τα εξής:

- **Γεωχωρικό Ευρετήριο (points.location: 2dsphere):** Απαραίτητο για την εκτέλεση γεωχωρικών ερωτημάτων (όπως $geoWithin και $near). Επιτρέπει στη MongoDB να εκτελεί γρήγορους υπολογισμούς σε σφαιρικές συντεταγμένες.
- **Sharding Key Index (ship_id: Hashed):** Επιλέχθηκε κατακερματισμένο (hashed) ευρετήριο στο ship_id. Αυτό διασφαλίζει την ομοιόμορφη κατανομή των δεδομένων (Uniform Distribution) στα τμήματα (shards) του cluster, αποτρέποντας τη δημιουργία "Hotspots" εγγραφής.
- **Χρονικό Ευρετήριο (bucket_period.start: Ascending):** Χρησιμοποιείται για το ταχύτερο φιλτράρισμα και ταξινόμηση των αποτελεσμάτων με βάση τον χρόνο (π.χ. εύρεση τροχιών μια συγκεκριμένης ημερομηνίας).
- **Ευρετήριο Τύπου Πλοίου (static_data.vessel_type: Ascending):** Βελτιώνει την απόδοση στατιστικών ερωτημάτων που ομαδοποιούν ή φιλτράρουν τα δεδομένα ανά κατηγορία πλοίου (π.χ. "Μόνο Επιβατηγά").

5. Ανάλυση Δεδομένων & Ερωτήματα (Data Analytics & Queries)

Στο παρόν κεφάλαιο παρουσιάζουμε παραδείγματα ανάλυσης δεδομένων που μπορεί να γίνει στην βάση που υλοποιήσαμε. Τα ερωτήματα που μπορούν να απαντηθούν αφορούν 4 κατηγορίες: περιγραφική στατιστική, γεωχωρική αναζήτηση, επιπτώσεις καιρού και σύνθετοι αλγοριθμικοί δείκτες.

5.1 Περιγραφική Στατιστική Στόλου (Descriptive Statistics)

Αρχικά, εξετάστηκε η κατανομή του στόλου και η συμπεριφορά των πλοίων βάσει των στατικών χαρακτηριστικών τους.

- Κατανομή Στίγματων ανά Τύπο (Query Q1): Ομαδοποιήθηκαν οι τύποι πλοίων ώστε να φανεί η πληθηκότητα τους στην βάση μας.
- Μέγιστη Ταχύτητα (Query Q2): Φιλτραρίστηκαν τιμές θορύβου >80 κόμβων που πρακτικά είναι αδύνατον να πιαστούν και υπολογίστηκε η μέγιστη ταχύτητα ανά τύπο πλοίου

```
[Q1] Συνολικά Στίγματα ανά Τύπο Πλοίου
 Χρόνος: 3.2118 sec
- Passenger: 2,028,676
- Unknown: 1,464,582
- Tanker: 1,022,209
- Tug: 964,890
- Pleasure Craft: 706,470
- Cargo: 700,927
- High Speed Craft: 668,704
- Other: 308,297
- Sailing: 80,011
- Fishing: 27,001
- Anti-pollution: 18,466
- Search and Rescue: 9,816
- Towing: 9,547
- Military: 2,038
- Diving: 504
- Dredging: 191
- Port Tender: 39

[Q2] Μέγιστη Ταχύτητα ανά Τύπο (Top 5)
 Χρόνος: 11.6440 sec
- Towing: 54.6 knots
- Unknown: 48.5 knots
- Sailing: 45.3 knots
- Pleasure Craft: 43.9 knots
- Passenger: 42.2 knots
```

5.2 Γεωχωρικά και Χωροχρονικά Ερωτήματα (Spatio-Temporal Queries)

Χρησιμοποιώντας το γεωχωρικό ευρετήριο 2dsphere εκτελέστηκαν τα ακόλουθα ερωτήματα γεωγραφικού εντοπισμού

- Αναζήτηση εντός Πολυγώνου (Query Q4): Χρησιμοποιώντας τον τελεστή $geoWithin ορίστηκε το πολύγωνο του Σαρωνικού ώστε να εντοπιστούν τα πλοία που διέσχισαν την περιοχή.
- Αναζήτηση εντός Ακτίνας (Query Q5): Εντοπίστηκαν πλοία σε ακτίνα 10 χλμ. από το λιμάνι του Πειραιά με χρήση του $centerSphere.
- Χωροχρονική Αναζήτηση (Query Q6): Παρόμοια με το ερώτημα Q4 ζητήσαμε τα πλοία που διέσχισαν τον Σαρωνικό το τριήμερο του δεκαπενταύγουστου.

```
[Q4] Πλοία στον Σαρωνικό (Πολύγωνο)
 Χρόνος: 1.5880 sec
- Βρέθηκαν 641 μοναδικά πλοία.

[Q5] Πλοία σε ακτίνα 10km από το κέντρο του Πειραιά
 Χρόνος: 8.5984 sec
- Βρέθηκαν 938 πλοία.

[Q6] Πλοία στον Σαρωνικό το τριήμερο του Δεκαπενταύγουστου
 Χρόνος: 1.0876 sec
- Βρέθηκαν 164 πλοία.
```

5.3 Ανάλυση Επίδρασης Καιρού (Weather Impact Analysis)

Με τον εμπλουτισμό των τροχιών με τις καιρικές συνθήκες μπορούμε να συσχετίσουμε την ναυσιπλοΐα με το περιβάλλον.

- Σύγκριση Ταχύτητας σε Άπνοια vs Φουρτούνα (Query Q9): Συγκρίθηκε η μέση ταχύτητα των πλοίων όταν η

ταχύτητα ανέμου ήταν <5 m/s (Άπνοια) έναντι συνθηκών >8 m/s (Φουρτούνα).

- Εντοπισμός Ακραίων Φαινομένων (Query Q7 & Q11): Αναζητήθηκαν στίγματα με ακραία καιρικά φαινόμενα (π.χ. άνεμος > 15 m/s ή μέγιστη θερμοκρασία), αναδεικνύοντας τη δυνατότητα του συστήματος να λειτουργήσει ως εργαλείο ιστορικής ανάλυσης καιρού.

```
[Q7] Στίγματα με δυνατό άνεμο (> 15 m/s) & Έλεγχος Χρονικής Διαφοράς
 Χρόνος: 4.3759 sec
- Δεν βρέθηκαν στίγματα με τόσο δυνατό άνεμο.
```

```
[Q9] Επίδραση Καιρού στην Ταχύτητα (Άπνοια vs Φουρτούνα)
 Χρόνος: 16.2793 sec
- Μέση Ταχύτητα σε Άπνοια (<5):   11.75 knots
- Μέση Ταχύτητα σε Φουρτούνα(>8): 11.30 knots
 Συμπέρασμα: Ταχύτητα μειωμένη κατά 3.9% λόγω καιρού.
```

```
[Q11] Ρεκόρ Υψηλότερης Θερμοκρασίας
Χρόνος: 13.4325 sec
Θερμοκρασία: 29.4 °C
Πλοίο: 62127e80937feee20d7d3d3e79ee47e01192df1c9fad09311cde8702aca293aa (Cargo)
Πότε: 2017-08-01 11:10:42
Πού: [23.6224333333333, 37.8011]
```

5.4 Προηγμένη Αλγόριθμική Ανάλυση: Δείκτης Tortuosity (Computational Analytics)

Ένα από τα πιο σύνθετα ερωτήματα που μπορεί να απαντήσει ο τρόπος υλοποίησης που κάναμε αφορά τον υπολογισμό του δείκτη **Tortuosity.** Ο δείκτης αυτός ποσοτικοποιεί την καμπυλότητα της πορείας ενός πλοίου και ορίζετε ως την πραγματική απόσταση που διένυσε προς την ευθεία (ευκλείδεια) απόσταση.

Σκοπός: Ο εντοπισμός πλοίων που κάνουν ελιγμούς λόγω κακοκαιρίας.
Μεθοδολογία: Για τον υπολογισμό της συντομότερης απόστασης μεταξύ δύο σημείων πάνω στην επιφάνεια μιας σφαίρας, χρησιμοποιήθηκε ο τύπος Haversine. Χρησιμοποιήθηκε ο τελεστής $function που επιτρέπει την εκτέλεση κώδικα JavaScript μέσα στην βάση, αποφεύγοντας τη μεταφορά δεδομένων στην εφαρμογή.

```
Ship ID: 9391b035f988aa277e7e11a7f0e2377cce62e0ee5f367643c69001b526a81263 (High Speed Craft)
   Time Start:       2017-08-13 18:45:24
   Avg Wind Speed:   10.7 m/s
   Actual Distance:  18.07 km
   Displacement:     2.07 km
   Tortuosity Index: 8.73
   [Check Math]:     18.07 / 2.07 = 8.73
------------------------------------------------------------
Ship ID: 57139e85177dea04c5a366a3c24ca31a613754c1379d3e5cd844995e479ddf07 (High Speed Craft)
   Time Start:       2017-08-11 16:50:48
   Avg Wind Speed:   10.7 m/s
   Actual Distance:  19.48 km
   Displacement:     2.69 km
   Tortuosity Index: 7.25
   [Check Math]:     19.48 / 2.69 = 7.25
```

6. Πειραματική Αξιολόγηση (Experimental Evaluation)

Στην παρούσα ενότητα θα αξιολογήσουμε την απόδοση και την κλιμακωσιμότητα του συστήματος. Σχεδιάστηκαν 3 πειράματα ώστε να μετρηθεί ο χρόνος απόκρισης σε συνάρτηση με τρεις κρίσιμες παραμέτρους: τον όγκο των δεδομένων, τη γεωχωρική επιλεκτικότητα και τη χρήση ευρετηρίων.

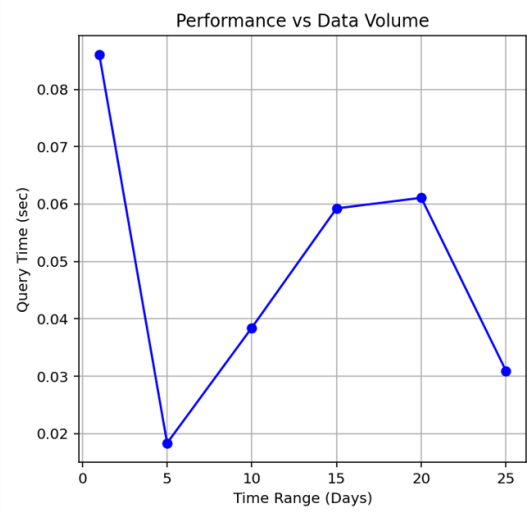
6.1 Πείραμα 1: Κλιμακωσιμότητα Όγκου Δεδομένων (Data Volume Scalability)

Στο πρώτο πείραμα εξετάσαμε την συμπεριφορά του συστήματος καθώς αυξάνεται ο χρονικός ορίζοντας της αναζήτησης μας και κα' επέκταση το πλήθος εγγραφών.

Εκτελέστηκαν ερωτήματα καταμέτρησης (count) για διαστήματα από 1 έως 25 ημέρες.

- **1 Ημέρα (3.748 εγγραφές):** 0,0860 sec
- **5 Ημέρες (23.686 εγγραφές):** 0,0183 sec
- **10 Ημέρες (58.247 εγγραφές):** 0,0385 sec
- **15 Ημέρες (85.098 εγγραφές):** 0,0592 sec
- **20 Ημέρες (99.626 εγγραφές):** 0,0611 sec
- **25 Ημέρες (120.821εγγραφές):** 0,0310 sec

Παρατηρούμε ότι ο χρόνος των ερωτημάτων έχει μια γραμμική αύξηση. Η ανωμαλία που παρατηρούμε από την μια μέρα στις πέντε και από τις είκοσι στις εικοσιπέντε πιθανών οφείλετε στο **cache warming.** Έχουν ήδη φορτωθεί έγγραφα στην μνήμη οπότε δεν χρειάζεται να ξαναπροσπελαστούν. Η χρήση του χρονικού ευρετήριο (bucket_period) επιτρέπει στην MongoDB να φιλτράρει εκατοντάδες χιλιάδες εγγραφές, χωρίς να επηρεάζεται από το μέγεθος της συλλογής.



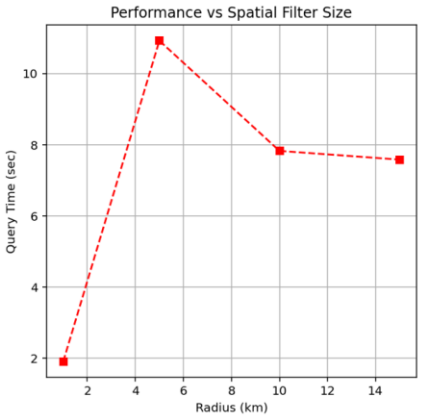
6.2 Πείραμα 2: Γεωχωρική Επιλεκτικότητα (Spatial Selectivity)

Στο δεύτερο πείραμα εξετάσαμε το υπολογιστικό κόστος των γεωχωρικών ερωτημάτων. Ζητήθηκε στην βάση η εύρεση πλοίων εντός μια κυκλικής περιοχής με κέντρο τον Πειραιά αυξάνοντας σταδιακά την ακτίνα αναζήτησης.

- **Ακτίνα 1 km:** 1,9078 sec
- **Ακτίνα 5 km:** 10,9267 sec
- **Ακτίνα 10 km:** 7,8290 sec
- **Ακτίνα 15 km:** 7,5837 sec

Παρατηρούμε ότι ο χρόνος αυξάνετε απότομα στην μετάβαση από ακτίνα 1km σε 5km. Αυτή η αύξηση είναι απόλυτα δικαιολογημένη και οφείλετε στην γεωμετρία. Πενταπλασιάζοντας την ακτίνα (1km → 5km), το εμβαδόν αναζήτησης αυξάνεται κατά 25 φορές ($Area \approx r^2$).

Στις ακτίνες 10 km και 15 km παρατηρείται μείωση του χρόνου, παρότι η έκταση τετραπλασιάστηκε. Το φαινόμενο μπορεί να ερμηνευτεί ως αποτέλεσμα του **cache warming:** το πιο απαιτητικό ερώτημα για την ακτίνα των 5 km προκάλεσε την ανάγνωση και τη φόρτωση των σχετικών σελίδων δεδομένων στη μνήμη. Έτσι, οι επόμενες αναζητήσεις εξυπηρετήθηκαν κυρίως από τη RAM, δηλαδή από ήδη "ζεστά" δεδομένα, και δεν χρειάστηκε αντίστοιχα χρόνος για επαναλαμβανόμενη πρόσβαση στον δίσκο (disk I/O).

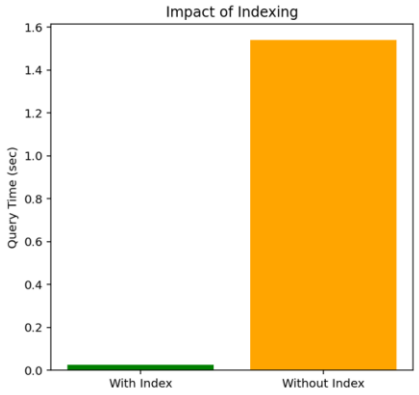


6.3 Πείραμα 3: Επίδραση Ευρετηρίασης (Indexing Impact)

Στο τρίτο πείραμα συγκρίθηκε ο χρόνος ανάκτησης ενός συγκεκριμένου πλοίου (ship_id) με και χωρίς τη χρήση ευρετηρίου.

- **Με Ευρετήριο (With Index):** 0,026896 sec
- **Χωρίς Ευρετήριο (Full Scan):** 1,539242sec
- **Βελτίωση (Speedup):** 57,2x

Η χρήση Hashed Index στο πεδίο ship_id οδήγησε σε επιτάχυνση περίπου 57,2 φορές σε σύγκριση με την προηγούμενη προσέγγιση. Όταν δεν έχει οριστεί ευρετήριο, η βάση δεδομένων αναγκάζεται να κάνει Full Collection Scan. Αυτό σημαίνει ότι ελέγχει με σειρά όλα τα έγγραφα της συλλογής και τα διαβάζει ένα-ένα, μέχρι να βρει όσα ικανοποιούν το ερώτημα. Το πείραμα δείχνει ότι η στρατηγική ευρετηρίασης που εφαρμόστηκε είναι απαραίτητη για να λειτουργεί σωστά το σύστημα σε περιβάλλον Big Data.



6.4 Μετρικές Δεδομένων & Αποδοτικότητα Αποθήκευσης

Η αξιολόγηση της βάσης δεδομένων πραγματοποιήθηκε σε ένα σύνολο πραγματικών δεδομένων AIS, το οποίο περιλάμβανε **8.012.368** μοναδικές εγγραφές (στίγματα GPS). Η υλοποίηση του σχήματος (Schema Design) και η χρήση της MongoDB οδήγησαν στα ακόλουθα μετρήσιμα αποτελέσματα:

- **Αποδοτικότητα Συμπίεσης (Storage Efficiency):** Ο λογικός όγκος των δεδομένων (Data Size), λόγω της δομής JSON και του εμπλουτισμού με μετεωρολογικά δεδομένα, ανέρχεται στα **2.04 GB**. Ωστόσο, ο πραγματικός χώρος που καταλαμβάνει η βάση στον δίσκο (Storage Size) περιορίστηκε στα **332 MB**. Αυτό καταδεικνύει ότι επιτεύχθηκε εξαιρετικά υψηλός λόγος συμπίεσης (~6:1) χάρη στον μηχανισμό WiredTiger Storage Engine.
- **Μείωση Πολυπλοκότητας (Cardinality Reduction):** Με την εφαρμογή του Bucket Pattern, τα 8 εκατομμύρια στίγματα ομαδοποιήθηκαν σε **122.366** έγγραφα (buckets). Αυτή η δραστική μείωση του πλήθους των εγγραφών ελαχιστοποίησε το διαχειριστικό κόστος (overhead) της βάσης και το μέγεθος των ευρετηρίων.

7. Συμπεράσματα και Προτάσεις για Μελλοντική Εργασία

7.1 Συμπεράσματα

Στην παρούσα εργασία εξετάστηκε η σχεδίαση και η υλοποίηση ενός συστήματος διαχείρισης Μεγάλων Δεδομένων (Big Data) για εφαρμογές στη ναυτιλία, με στόχο τον χωροχρονικό εμπλουτισμό των τροχιών AIS μέσω ενσωμάτωσης μετεωρολογικών δεδομένων.

Από την υλοποίηση και τα πειράματα προέκυψαν τα εξής βασικά συμπεράσματα:

1. **Η υπεροχή του Bucket Pattern:** Η αποθήκευση των δεδομένων σε χρονικά «πακέτα» (buckets) και όχι ως μεμονωμένα στίγματα, αποτέλεσε την πιο καθοριστική επιλογή στον σχεδιασμό. Η ομαδοποίηση αυτή επέτρεψε την πιο σταθερή διαχείριση των εγγραφών στον χρόνο, καθιστώντας τη συνολική επεξεργασία πρακτική. Η μείωση του μεγέθους των ευρετηρίων (Index Size) οδήγησε σε μικρότερη καθυστέρηση ανάγνωσης (Read Latency), καθώς πλέον ανακτώνται ολόκληρα τμήματα ταξιδιού με μία μόνο λειτουργία δίσκου (I/O operation).
2. **Ακρίβεια Χωροχρονικής Συσχέτισης:** Η απλή γεωγραφική σύνδεση (Spatial Join) αποδείχθηκε ανεπαρκής για κινούμενα αντικείμενα σε διαρκώς μεταβαλλόμενο περιβάλλον. Ο αλγόριθμος τριών σταδίων που αναπτύχθηκε (**α.Χρονικό Φιλτράρισμα β.Γεωχωρικός Γείτονας γ.Χρονική Ελαχιστοποίηση**) επέτρεψε την ακριβή αντιστοίχιση των μετεωρολογικών δεδομένων με το αντίστοιχο πλοίο, εξαλείφοντας τις λανθασμένες συσχετίσεις που προκύπτουν από την απλή γεωγραφική εγγύτητα.
3. **Κλιμακωσιμότητα (Scalability):** Τα πειράματα φόρτου έδειξαν ότι η απόδοση του συστήματος μεταβάλλεται γραμμικά. Ο χρόνος επεξεργασίας αυξάνεται αναλογικά με τον όγκο των δεδομένων και όχι εκθετικά. Αυτό αποδεικνύει ότι η συγκεκριμένη αρχιτεκτονική (Sharding + Indexing) μπορεί να κλιμακωθεί σε πολύ μεγαλύτερα σύνολα δεδομένων, χωρίς να προκύπτει αστάθεια ή κατάρρευση του συστήματος.
4. **Διαχείριση Θορύβου και Γεωμετρίας:** Η ανάλυση κατέδειξε ότι στα πραγματικά δεδομένα εμφανίζονται συχνά σφάλματα GPS, τα οποία δημιουργούν πλασματικές ταχύτητες. Παράλληλα, διαπιστώθηκε ότι το υπολογιστικό κόστος αυξάνεται ραγδαία με την αύξηση της ακτίνας αναζήτησης (νόμος r^2).
5. Για τη διατήρηση της απόδοσης, κρίθηκε αναγκαία η εφαρμογή φίλτρων καθαρισμού και η χρήση εξειδικευμένων ευρετηρίων 2dsphere.

7.2 Μελλοντικές Επεκτάσεις (Future Work)

Παρότι το σύστημα καλύπτει επιτυχώς τις ανάγκες της ιστορικής ανάλυσης, υπάρχουν σαφή περιθώρια περαιτέρω ανάπτυξης για την υποστήριξη επιχειρησιακών απαιτήσεων σε πραγματικό χρόνο:

1. **Επεξεργασία Ροής (Real-time Streaming):** Η τρέχουσα υλοποίηση βασίζεται σε Batch Processing. Μια βασική κατεύθυνση επέκτασης είναι η ενσωμάτωση του **Apache Kafka** για τη λήψη σημάτων AIS σε πραγματικό χρόνο και η χρήση **Spark Streaming** για τον άμεσο εμπλουτισμό τους με πληροφορίες καιρού, προσφέροντας δυνατότητες Live Monitoring.
2. **Μηχανική Μάθηση (Machine Learning):** Τα εμπλουτισμένα δεδομένα (Ταχύτητα, Καιρός, Τύπος Πλοίου) προσφέρουν το κατάλληλο υπόβαθρο για την εκπαίδευση μοντέλων. Μελλοντικά μοντέλα θα μπορούσαν να εκτιμούν την **Εκτιμώμενη Ώρα Άφιξης (ETA)** λαμβάνοντας υπόψη τον καιρό, ή να εφαρμόζουν μεθόδους **Ανίχνευσης Ανωμαλιών (Anomaly Detection)** για τον εντοπισμό ύποπτων μοτίβων κίνησης (π.χ. παράνομη αλιεία ή λαθρεμπόριο).
3. **Οπτικοποίηση (Visualization Dashboard):** Σχεδιασμός και υλοποίηση μιας διαδικτυακής διεπαφής (Web UI) με χρήση βιβλιοθηκών χαρτογράφησης (π.χ. Leaflet ή Mapbox). Η διεπαφή θα επιτρέπει την προβολή χωρικών δεδομένων, τη διαδραστική περιήγηση στις τροχιές και την οπτικοποίηση των καιρικών φαινομένων, αντικαθιστώντας τα στατικά αποτελέσματα με δυναμικούς πίνακες ελέγχου.
4. **Distributed Computing:** Για την ανάλυση δεδομένων που καλύπτουν πολλά έτη (Big Data Analytics), προτείνεται η μεταφορά του φορτίου επεξεργασίας από την Python (Pandas) σε ένα κατανεμημένο framework όπως το **Apache Spark**. Έτσι, θα αξιοποιηθούν πλήρως οι πόροι του cluster της MongoDB για παράλληλη επεξεργασία μεγάλης κλίμακας.

8. Βιβλιογραφία

[1] Dong Yang, Lingxiao Wu, Shuaian Wang, Haiying Jia & Kevin X. Li (2019) How
big data enriches maritime research – a critical review of Automatic Identification System (AIS)
data applications, Transport Reviews, 39:6, 755-773,
https://doi.org/10.1080/01441647.2019.1649315

[2] R. Aguilar Vera, A. Naal Jácome, J. Díaz Mendoza, and O. Gómez Gómez, "NoSQL Database Modeling and Management: A Systematic Literature Review," Revista Facultad de Ingeniería, vol. 32, no. 65, e16519, 2023.
doi: 10.19053/01211129.v32.n65.2023.16519.

[3] Y. Zheng, "Trajectory data mining: An overview," *ACM Transactions on Intelligent Systems and Technology (TIST)*, vol. 6, no. 3, pp. 1–41, 2015.

[4] Vettor, R., & Guedes Soares, C. (2016). "Development of a Ship Weather Routing System". Ocean Engineering, 117, 375-388.
https://doi.org/10.1016/j.oceaneng.2016.06.035